招采公告与附件数据质量分析报告

初赛过程性文档 | 2026-10-14 | 版本 1.1

数据质量分析报告

1 数据范围与质量结论

系统已对 1,038 条采购公告及其附件完成本地处理与分类盘点，能够对复杂格式、失败附件、参考材料和无效下载响应保留来源并隔离处理。数据治理重点是让可用内容继续进入抽取流程，让异常内容可解释、可追溯，不让单个坏附件中断整批任务。

本报告同时记录 2026-09-30 的附件快照和 2026-10-14 的官方结果补录复核。解析覆盖、字段抽取正确性和查询实现一致性是不同指标；解析产生文本不能直接视作七字段正确。

2 全量附件快照

统计项	数量	含义
公告	1,038	全量材料快照的公告数
附件叶文件	13,136	展开后文件，不含公告 HTML
成功或部分解析	12,124	获得文本、OCR 或表格结果
参考材料保留但不解析	986	按用途识别，保留来源
程序解析失败	19	17 PDF、2 DOC，按附件隔离
不支持格式	7	6 DWG、1 GBQ7，保留来源与告警
无效下载响应	87	进入解析前排除，另行统计
有 OCR 告警的公告	359	涉及 OCR 路径，不代表识别正确

附件叶文件分类满足 12,124 + 986 + 19 + 7 = 13,136。87 个无效下载响应在解析前被识别，因此不再计入该分类总和。快照与分类详情见 docs/benchmarks/official-attachments-20260930.json。

3 质量控制方法

环节	控制措施	输出给用户的信息
内容识别	比对实际内容与扩展名；识别旧式 Office、WPS 和专有格式	实际格式、来源和格式差异告警
归档展开	限制深度、成员数和大小；损坏成员独立隔离	成员读取失败、超限和路径来源
文档解析	PDF 主解析器与回退、Office 转换、OCR	成功、部分成功、程序失败和 OCR 状态
材料用途	区分本次采购、历史案例、合同范本和参考材料	用途判断、过滤理由和保留来源
候选抽取	schema、数值、包号证据和跨文件对齐保护	字段、连续证据、冲突和 default 警告
人工复核	按质量信号排序，保留决定及前后值	接受、修正、驳回和事件历史

WPS 进入旧 Word 转换路径；GBQ7 和 DWG 明确保留为不支持格式。无效响应、不可恢复源文件和不支持内容不由模型补造。PDF 定向恢复或后续解析修复属于单独实验，不改写这份冻结快照。

4 字段与关系质量

七字段保存源材料中可支持的信息。项目总金额、中标主体金额和单个标的总价分别建模；金额保留十进制精度和单位。当前查询只汇总已披露的标的总价，不通过数量和单价替代原文缺失值。采购人天服务、税金等因素可能造成标的合计与项目总额不一致，不能据此自动判错。

品牌与中标供应商分别处理，不以法律实体名称自动补品牌。参与主体保存 winner、nonwinner、unknown，结果未披露不等于未中标。名称型包号要求明确标签和值；缺可靠映射时使用 default，并提示包级统计可能合并。

5 官方结果补录与缺失分布

本轮使用保留的 1,038 份公告及压缩包，离线补录评审表、投标报价、得分和未中标原因等附表字段；不调用模型，也不覆盖原有任务一投影。补录扫描到 14,174 个来源成员，形成 6,477 条结构化观察；986 个成员按参考材料过滤，19 个成员单独记录为解析失败，311 个 PDF 因无可提取文字标记为需要人工查看，另有 262 个成员属于不支持格式或扫描待复核。该补录使用文本解析，未启用扫描件 OCR，因此这些记录不能宣称已完成字段抽取。

结果表抽取列	非空行数	空值行数	口径
总表·中标供应商	1,315	538	1,853 行总表；只统计来源明确的中标记录
标的表·产品服务名称	6,459	13	6,472 行标的表；照录来源名称
标的表·品目	3,095	3,377	不凭产品名称补造品目
标的表·品牌	4,992	1,480	不用供应商名称代替品牌
标的表·规格型号	4,950	1,522	原文未可靠提取时留空
标的表·数量	5,911	561	保留可确认的数量
标的表·单价	4,193	2,279	6,472 行标的表；保留万元换算后的全部有效小数
标的表·总价	3,630	2,842	不以单价×数量覆盖缺失或冲突原值
投标人表·通过审查	4,030	1,376	5,406 行投标人表；仅有明确审查结论才填写
投标人表·报价	300	5,106	没有可靠货币单位时留空
投标人表·得分	4,358	1,048	不把排名当得分
投标人表·未中标原因	1,047	4,359	原文未披露时留空

表中“空值”表示当前抽取没有足够证据，不等于原文未披露。来源处理计数来自补录回执，非空与空值计数直接扫描最终工作簿生成；两者分别描述处理过程和最终导出结果。

全量 HTML 公告的源包号与数据库包记录复核结果为 1,038/1,038 公告缺失 0、包号不一致 0；该覆盖不包含无法从 HTML 直接判断的附件内部包号。标的单价×数量与已披露总价的精确比较发现 11 条差异，均保留原文总价并在结果表“备注”列标记，未自动改写。

6 来源证据与复核流程

新导入保存可获得的采购单位元数据证据、标的列级证据、明确未公示或空单元格状态以及输入 SHA-256。公告详情显示来源文件、定位、片段、警告和哈希。同名文件对应多个哈希时提示歧义，不把错误哈希当作证据。

历史数据中未保存的证据不能追溯生成：非空旧值显示待核验，旧空值保留未知状态。哈希只用于核对文件内容，不等于保存原件；应用不提供未保留原始字节的旧附件下载。

人工复核队列根据字段缺失、证据不足、OCR 或附件告警、default 包号和金额冲突排序。接受、修正和驳回记录操作者、时间、理由及前后值，候选代次防止重新导入后串接旧历史。复核覆盖与原机器候选分开保存，不自动回写 Gold 或改变统计结果。

7 本地标注与质量复查

团队 reviewed 数据用于逐条对照原文和开发回归，预测不作为真值。当前 24 条样本已经参与过诊断，后续指标保持本地回归口径。来源修订生成 Gold v2 并保留旧版及修改台账；不覆盖历史预测和报告，不把两种 Gold 或两种 profile 的数字直接比较。

真实开发迭代证据来自 2026-10-09 固定的 24 条 reviewed 回归集：同口径的历史附件用途候选由 5、9 条降为 0，PDF 历史候选由 9 条降为 0；跨文件候选融合由 332 条降为 309 条且包数保持 59；cache-only 回放中 hybrid 153→146、model 149→139，10 条缺少 parse cache 被隔离，新模型请求为 0。这些数字是固定输入上的诊断对比，不是 1,038 条官方准确率，也不与本轮补录观察数相加。

质量复查覆盖正文表格、附件表格、扫描件、旧式 Office、多包、多中标人、零候选及异常响应。复查项包括公告身份、包号、七字段、采购单位、参与角色、来源定位、哈希、告警和处理决定。独立保留异常记录，避免只抽查成功案例。

8 交付与数据管理

公开仓库提供解析代码、测试、schema、虚构样例和聚合质量统计。任务一结果表、任务二关系模型和运行清单按比赛要求进入受控交付包；API Key、评审密码、原始模型响应和本机路径不随公开仓库发布。

统计的日期、输入范围和失败分类均可回溯至快照。1,038 条处理完成说明管线具备实际材料处理能力；字段准确性以明确 Gold、指标 profile 和匹配边界下的本地结果表述。该区分使评委可以分别核查系统能力、数据质量和算法效果。