招采数据智能分析引擎系统设计报告

初赛作品说明 · 2026-10-11 · 版本 1.0

核心成果预览

本作品面向采购业务人员和数据核查人员，将分散在公告与复杂附件中的信息转成可检索的实体、可解释的关系和可追溯的复核记录。系统已形成材料导入、七字段抽取、五类关系查询、来源证据查看、人工复核和公告版本比较的完整操作链路。

业务需求	已实现能力	可演示结果
从复杂材料取数	HTML、Office、PDF、图片 OCR、ZIP/RAR/7z；三条抽取路线	七字段、采购单位、参与主体、中标记录与解析告警
从结果回到原文	新导入保存文件哈希、来源定位、字段证据与空值状态	在公告详情中查看证据片段和来源
从实体发现关系	五类查询、关系线索卡、图搜索、有界 1-hop 子图	查看项目数、包数、金额和关联公告
从候选形成复核记录	接受、修正、驳回；保存理由、前后值和候选代次	复核事件与机器候选分离保存
从单次导入扩展到批处理	目录浏览预检、有界并发、检查点、暂停续跑	可恢复任务和逐公告结果

截至代码基线 c1fc4c4 的验收记录，后端 662 项测试通过，前端 80 项通过，Ruff 和生产构建通过。2026-09-30 全量材料快照覆盖 1,038 条公告和 13,136 个附件叶文件。测试与材料处理数量属于团队工程验证，不能替代字段质量指标。

1 业务需求与技术选型

任务一提取产品或服务名称、品目、品牌、规格型号、单价、数量、总价，并保存采购单位、投标主体和中标记录。任务二围绕采购单位、供应商、项目和采购包建立关系，支持五类指定查询。任务三通过 Vue 分析台提供导入、检索、统计、图展示和复核入口。

系统优先保存事实和来源。原文未披露的信息保留空值；名称型包号只有在明确标签和值的连续证据通过校验时接受。自动抽取结果作为候选进入系统，人工修正以独立覆盖记录保存，不回写原始机器候选或自动改变统计结果。

技术选择	采用理由与职责
Vue 3 与 Vite	将分析、图搜索、证据弹层、复核和版本历史组织为可交互工作台
Python 与 FastAPI	统一多格式解析、模型调用、严格结构校验和业务 API
SQLite	每数据集独立文件，部署轻量；承担写入、默认查询和图投影
Neo4j	可选五类分析后端；连接、同步或查询失败时按请求回退 SQLite
Qwen 或 DeepSeek 兼容 API	配置化使用模型语义能力；规则路线保留离线处理能力
本地 OCR 与 Office 转换	为扫描件和旧式文档建立统一文本入口，记录处理来源与告警

2 总体架构

数据依次经过内容识别与归档展开、文本与表格解析、三路线抽取、用途与证据校验、候选持久化，再由查询和复核模块消费。解析、模型请求与任务队列分别设置并发边界，避免批处理无限累积请求和文档对象。

浏览器通过 FastAPI 访问当前数据集；X-Dataset-ID 控制数据集选择。五类分析 API 可读取 Neo4j 数据集镜像，响应报告实际后端；图搜索和关系线索读取 SQLite。公告版本保存不可变快照，版本比较读取冻结证据，不覆盖原版本。

3 数据模型与统计口径

数据对象	核心职责与关系
organizations	采购单位、供应商和投标主体；保留原名与别名，保守归一
projects 与 packages	公告项目和采购包；项目频次与包数分别统计
bid_participations	主体参与采购包的关系；区分 winner、nonwinner、unknown
awards	明确中标关系及其金额；不以项目总额替代主体中标金额
procurement_items	标的七字段、来源定位、字段证据及抽取方法
复核事件	决定、操作者、时间、理由、前后值、候选代次
公告版本	身份、不可变快照、文件哈希、结构化差异及冻结证据

五类查询包括：采购单位的合作供应商与产品供应商；采购单位的高频参与主体和共同参与组合；指定中标供应商的共同竞标者；多供应商的共同采购单位；多供应商共同参与的项目。参与关系默认纳入已记录的 winner、nonwinner 和 unknown，结果未知不推断为未中标。

合作频次按项目去重，并保留包数和包明细。中标金额按唯一 award 记录累加，不按金额相同去重。产品供应商按赛题品牌口径单独展示，其金额只汇总已披露的标的总价，不分摊项目总额或中标交易额。详细定义见 docs/QUERY_SEMANTICS.md。

4 功能设计与使用路径

导入者可上传单条公告材料，或在服务器授权根目录内浏览批量材料、预检并创建任务。任务支持模式和 OCR 配置冻结、暂停、续跑、失败重试与幂等入库。

分析者可搜索主体或项目，在受控子图中查看关系，再由线索卡跳转公告证据。卡片可收起长明细，公告详情在视口居中显示并独立滚动。受控自然语言查询先展示解析场景和过滤条件，只执行五类白名单查询，拒绝任意 SQL、Cypher 和写操作。

复核者可按缺字段、证据缺失、OCR 告警、default 包号和金额冲突排序查看候选。版本历史可比较前后公告和附件变化；身份不明确的材料独立保存并提示确认。版本功能不自动把分析切换为“只统计最新版本”。

5 验证与成果

验证范围	已有结果	证据说明
后端自动化	662 passed，7 skipped，2 warnings	2026-10-11 基线 c1fc4c4；跳过项涉及 Neo4j、LibreOffice 和符号链接环境
前端与构建	80 passed；生产构建通过	保留主 bundle 体积提示
公告版本专项	88 passed	覆盖版本、比较、证据与隔离行为
全量材料处理快照	1,038 条公告；13,136 个附件叶文件	2026-09-30；体现处理与分类覆盖
查询一致性	SQLite/Neo4j 各 6471/6471	2026-10-08 GAP 2.12 团队 reviewed tuning Gold 对照记录

24 条 reviewed 数据上的三路线运行记录用于开发回归，已经参与过调试，不作为独立泛化结论。本报告沿用既有验收记录，文档整理期间没有重新调用模型或重跑全量数据。指标定义、时间范围和来源见技术路线与数据质量报告。

6 部署与运行保障

仓库提供依赖清单、环境示例、启动与停止脚本、离线样例、账号配置和局域网诊断。运行入口见 README.md，技术环境与命令见 docs/DEVELOPMENT.md。模型端点通过配置接入，无模型时可用 rules 路线完成离线导入和查询。

评审会话使用 HttpOnly、SameSite=Strict Cookie；HTTPS 部署启用 Secure 属性。批量目录访问限定在 INTAKE_ROOT，部署者负责该目录的文件写权限。API Key、密码和本地数据库不进入公开源码包。

源文件不可用、专有格式不支持和证据缺失均以明确状态呈现。应用不长期保存原始文件字节，历史缺失证据不补造。图投影使用 SQLite，Neo4j 控制五类分析 API；并发机制面向单机服务，不提供跨主机分布式锁。

7 配套资料

docs/ARCHITECTURE.md 保存架构与数据流；docs/QUERY_SEMANTICS.md 保存业务统计口径；docs/CHANGELOG.md 和 docs/archive/reports/agent-notice-versioning-report.md 保存验收记录；deliverables/source-data-index.md 说明源码、任务一结果表和任务二数据模型的交付结构。